Autoscaling mit AWS

Horizontale / vertikale Skalierung

- vertikal: mehr CPU/RAM
  - irgendwann ist Schluss
  - u.a. Overhead durch Kernel Context Switche
- horizontal
  - viele, potenziell schwächere Maschinen
  - Anwendung muss damit umgehen können

Herausforderungen bei horizontaler Skalierung (Applikationslayer)

- Persistente Daten dürfen nicht mehr lokal gespeichert werden
- Anwendung entweder stateless oder Speicherung der Session in Datenbank
- Datei-Upload nicht mehr lokal
  - S3
  - EFS
  - GlusterFS
  - ...
- Tasks soll(t)en über Queues verarbeitet werden und nicht lokal

Horizontale Skalierung (PostgreSQL)

- Von Haus aus Replication von Master zu Slave möglich
- Skalierung erfolgt über Middleware
  - master/master durch PgCluster möglich - bisher noch nicht eingesetzt
- pgPool
  - Master-Slave Replication, Queries können ge-loadbalanct werden
  - Mehrere pgPooler teilen sich eine virtuelle IP
  - Je nach Anforderung komplexe Konfiguration vorhanden (Load Balancing, Failover etc.)

Autoscaling mit AWS

- Autoscaling nur horizontal möglich
- Load Balancer (LB)
  - Verteilt eingehende Anfragen auf mehrere Backendsysteme
- Launch Configuration (LC)
  - Definiert AMI, Sicherheitsgruppen, Start-Script, Keypair usw.
- Autoscaling Group (ASG)
  - Nutzt eine LC
  - Minimale/maximale Anzahl Instanzen innerhalb der ASG
  - Zugeordnete Load Balancer

Launch Configuration

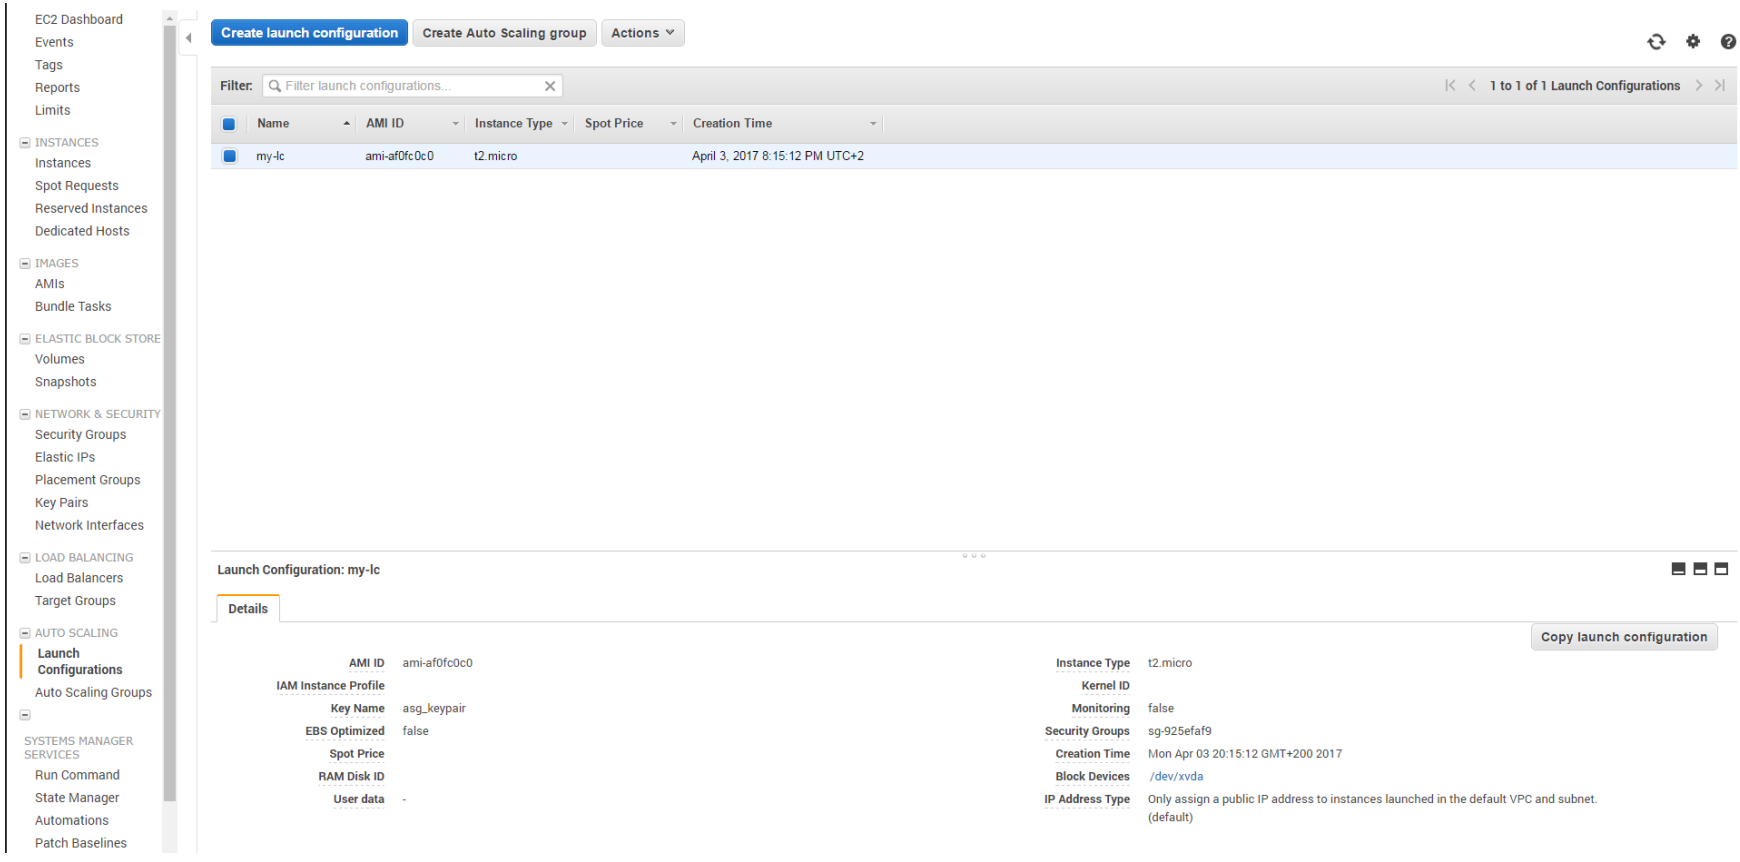

Autoscaling Group

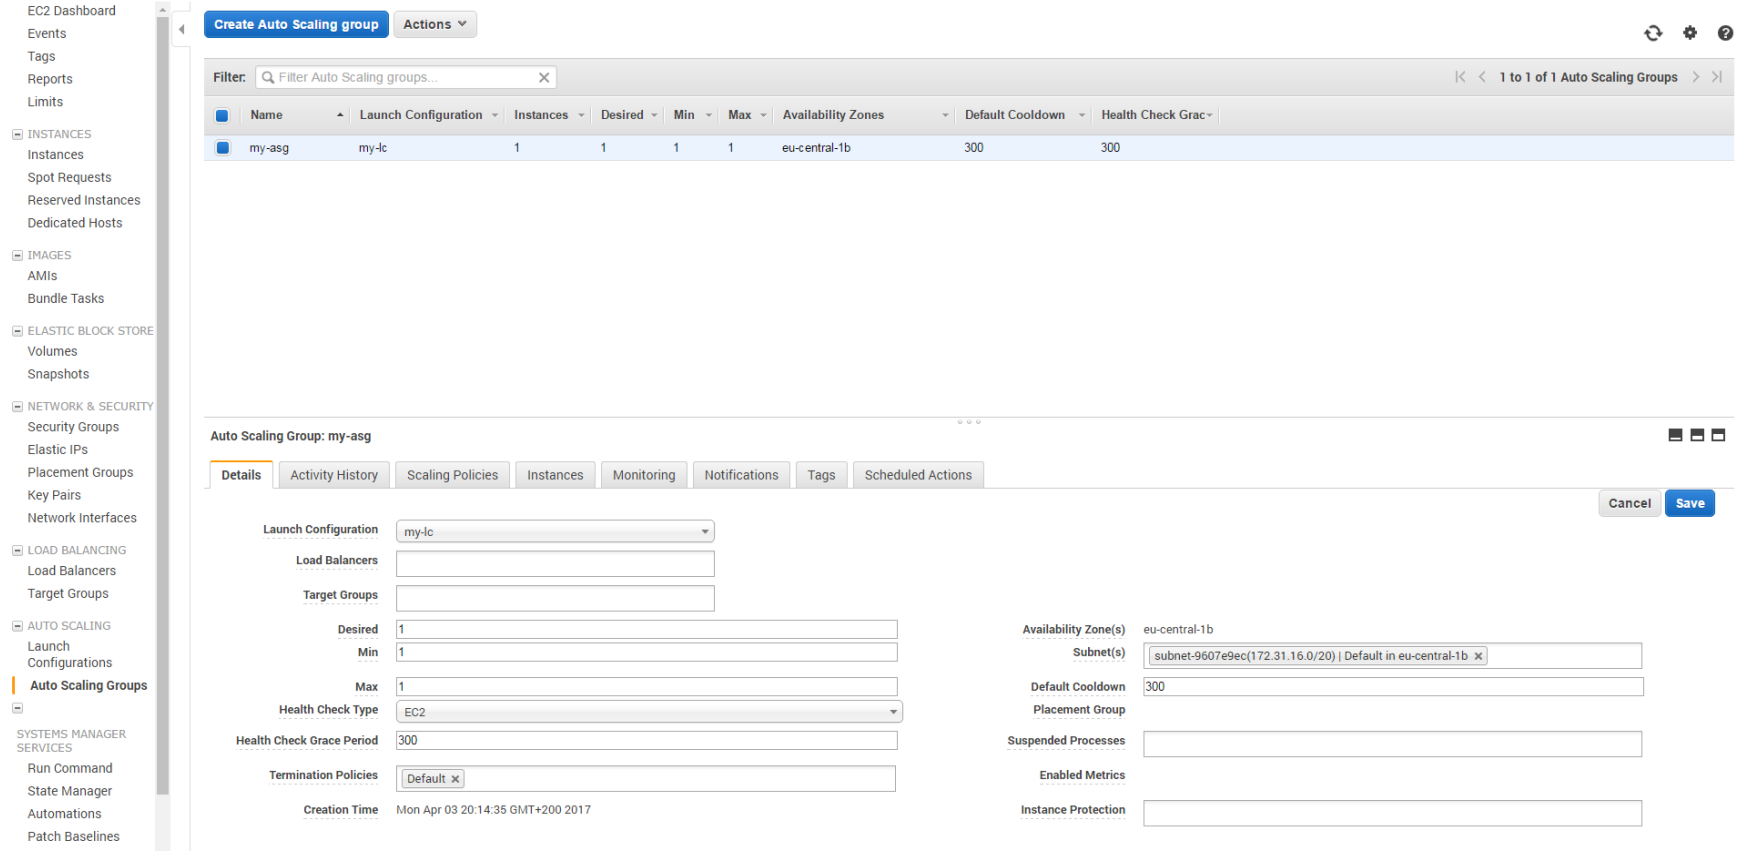

Wie wird skaliert?

- Scaling Policies
  - Wenn Wert X über Zeitraum Y mache Z
- Scheduled Actions
  - Zu Zeitpunkt X mache Z

Scaling Policies

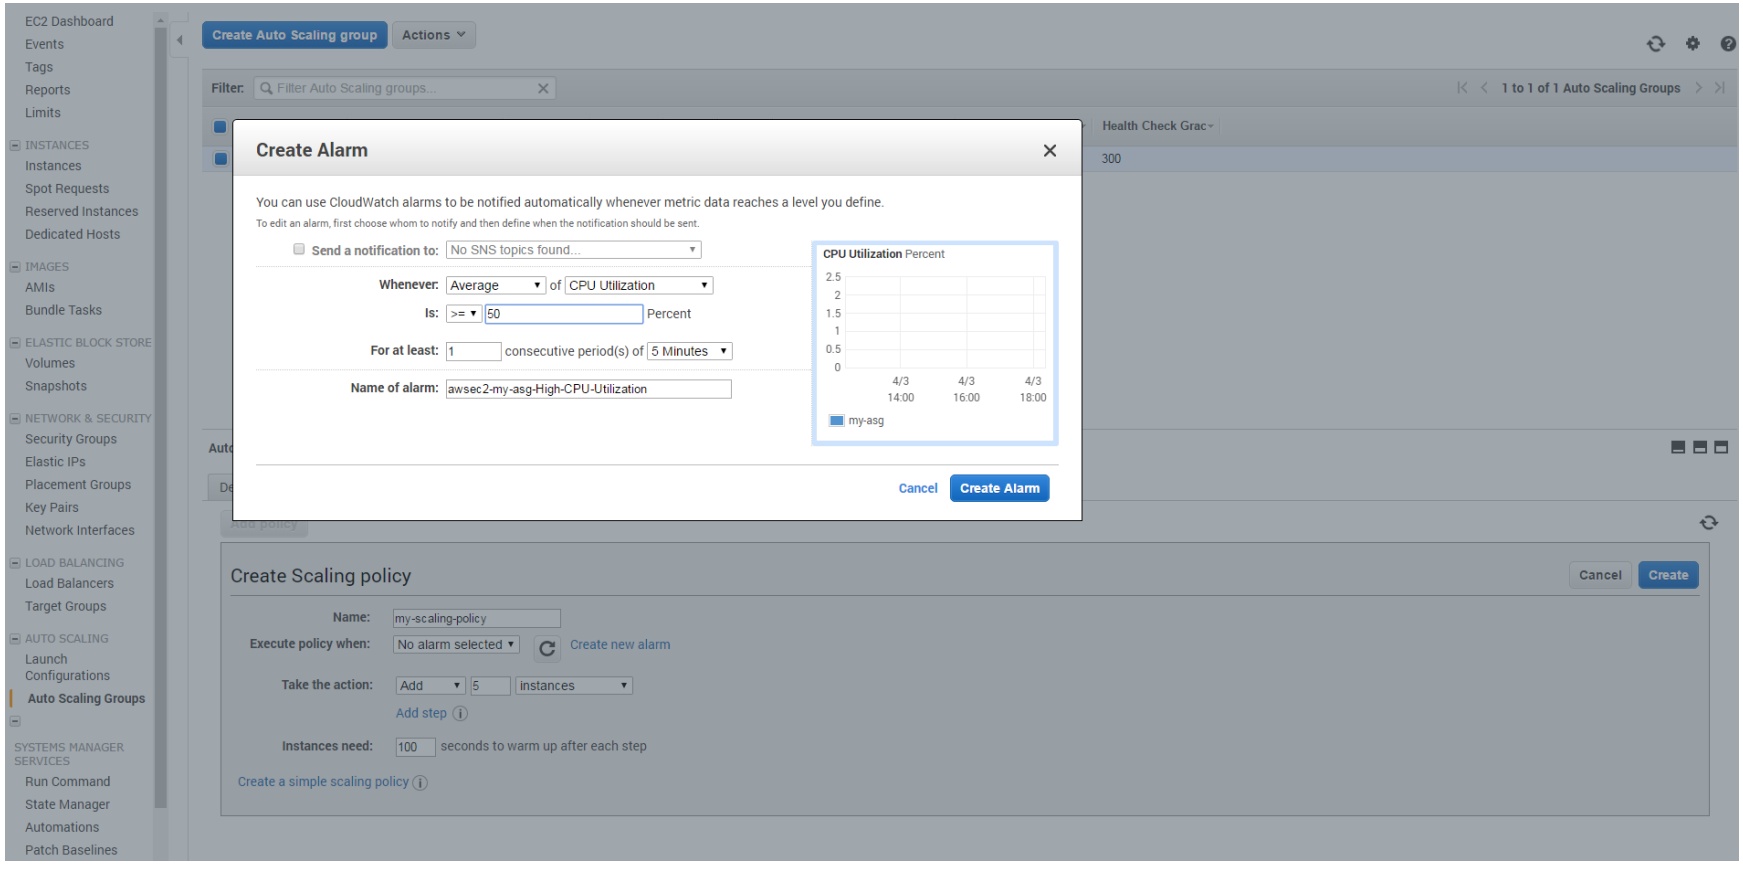

Scheduled Action

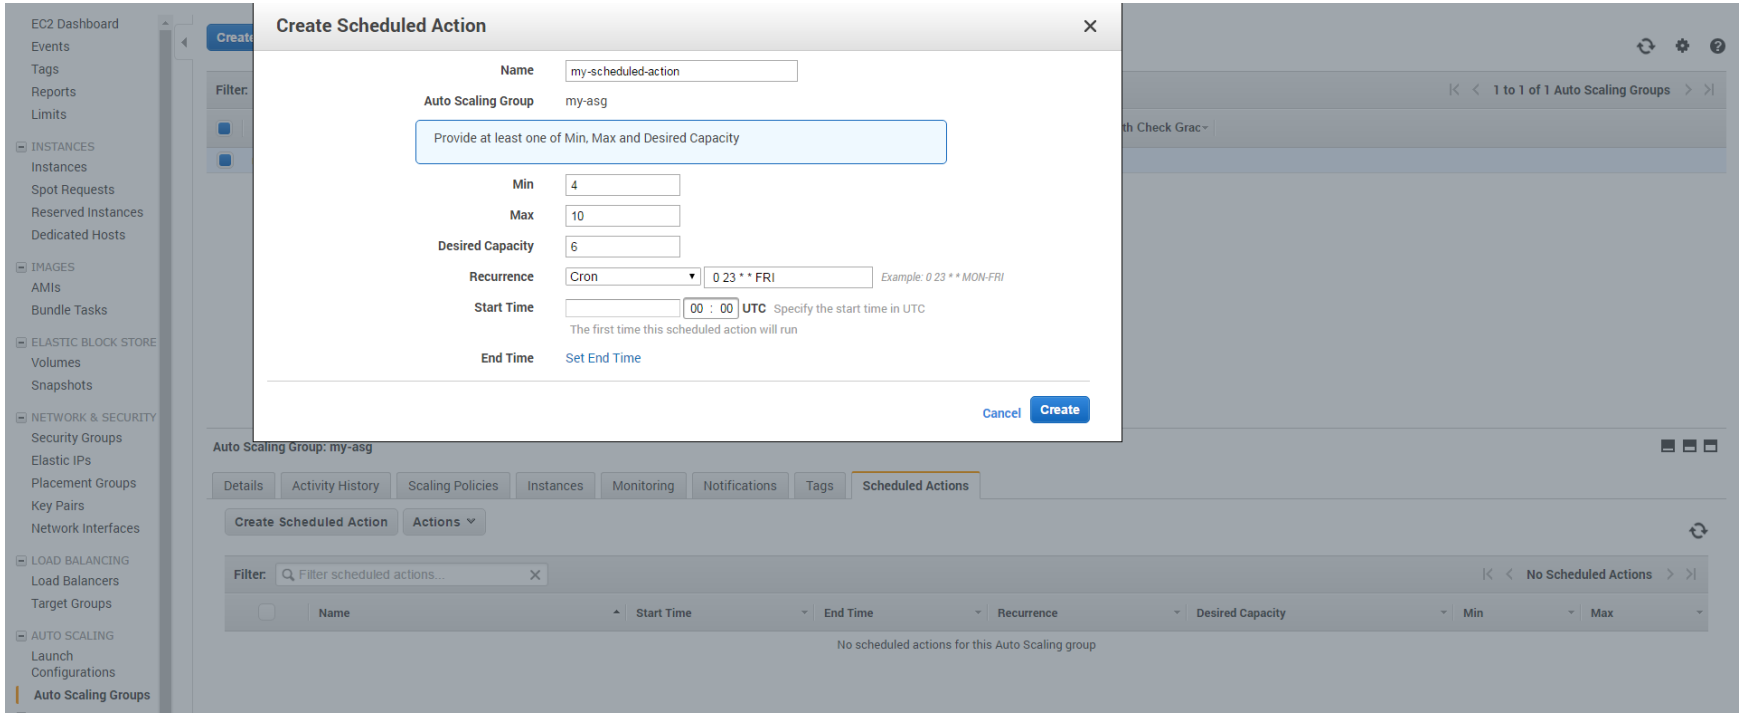

Wie bekomme ich meine App skaliert?

- Es gibt nicht "den einen" Weg - hängt vom bisherigen Projekt ab
- CodeDeploy
- Beanstalk
- Prebaked AMI und AWS API
- Configuration Management mit Chef oder Hosted Chef, Puppet oder Ansible
- Deployment mit Spinnaker
- ...

Fragen?

- Entweder per Twitter an @schakko
- oder per E-Mail an christopher.klein@neos-it.de